

빅데이터 분석 정의서

주제 : 멀티모달 라이프로그 감정 분석 기반
맞춤형 LLM 케어 및 모니터링 시스템

2026. 08. 28.

1. 개요

1) 아이디어 주제

- 멀티모달 라이프로그 감정 분석 기반 맞춤형 LLM 케어 및 모니터링 시스템

2) 개발 목표

- 스마트워치·체성분계를 통해 자동 수집되는 멀티모달 라이프로그 분석을 통해 기존 수동 감정 기록의 번거로움 개선
- 시계열 데이터 기반의 감정 변화 패턴 및 정서적 이상 징후의 선제적 조기 판별
- 데이터 기반 위험도 산출에 따른 맞춤형 LLM 인터랙션 및 개인화 케어 콘텐츠 제공

3) 개발 내용

- 웨어러블 기기(스마트워치)를 통한 시계열 생체 활동 데이터 및 대화 텍스트 데이터 실시간 수집 및 전처리
- 수집된 멀티모달 데이터를 융합 분석하여 감정 상태 추이 측정 및 우울, 스트레스 고위험 단계 자동 분류
- 분석된 위험도 단계에 맞춘 페르소나 기반 LLM 공감 대화 수행 및 개인 맞춤형 정서 케어 콘텐츠 추천

2. 기능별 빅데이터 분석 명세서

기능명	라이프로그 기반 시계열 이상 감지 및 정서 위험도 분석
1. 데이터 준비	
데이터 정의	- 스마트폰/웨어러블 기기(Health Connect API)로 수집되는 걸음 수(steps), 이동거리(distance), 소모칼로리(calories), 수면 데이터(총수면시간·깊은수면·얕은수면·REM수면·각성시간·입면시간·수면 효율), 심박수(heart_rate)·심박변이도(HRV) 시계열 데이터, 체성분 데이터(체중·체지방·체수분·기초대사량), 및 대화 텍스트 메타 데이터. 심박수·HRV 는 자율신경계 반응과 스트레스·정서 상태 간 상관관계가 선행연구(WESAD 등)에서 보고된 지표이다. - 다만 데이터 출처별로 확보 수준이 다르다. 기업 제공 데이터셋은 수면·활동·체성분 중심으로 구성되어 심박수·HRV 를 포함하지 않으며, 공개 데이터셋(PMData)은 분 단위 심박수를 제공하나 표준 SDNN 대신 일별 심박수 표준편차를 HRV 대용 지표로 산출한다. 실서비스에서는 Health Connect 가 제공하는 심박수·HRV 를 그대로 수집한다. 따라서 이탈 판정은 수면·활동 지표를 공통 입력으로 사용하고, 심박수·HRV 는 확보 가능한 구간에 한해 보조 입력으로 활용한다. - 체성분 항목은 수집 경로에 따라 확보 범위가 다르다. 실서비스의 Health Connect 는 체중·체지방·체수분·기초대사량을 제공하며, 근육량·골격근량은 제공하지 않는다. 기업 제공 데이터셋에는 근육량·골격근량을 포함한 항목이 모두 존재하므로, 데이터 모델은 두 경로를 모두 수용하도록 정의하되 실서비스 수집 항목은 Health Connect 기준을 따른다. - 활동량 지표 중에서는 걸음 수(steps)를 주 입력으로 사용하고, 이동거리·소모칼로리는 걸음 수와 상관성이 높아 보조 입력으로만 활용하여 특정 지표로의 편중을 방지한다. - 체성분 측정치는 수집 동의가 선택 항목이며 측정 빈도가 불규칙하므로 시계열 이상탐지 입력에서는 제외하고, 측정값이 존재하는 사용자에게 한해 개인별 기준값 보정(체중 대비 활동량 정규화)에만 활용한다.
데이터 획득 방법	- 클라이언트 앱 백그라운드 스케줄러를 통한 주기적(앱에서 최소 15분 간격 전송) 수집 및 HTTP/REST API 통신을 통한 백엔드 서버 이관 후 LIFELOG_METRICS 적재
수집 데이터	<pre>{ "user_id": "c39a12e0-5712-42ba-822d-60603126f000", "collected_at": "2026-07-26T21:30:00Z",</pre>

	<pre>"steps": 3200, "distance": 2100, "calories": 180, "activity_start_at": "2026-07-26T18:20:00Z", "activity_end_at": "2026-07-26T19:05:00Z", "total_active_min": 45, "sleep_start_at": "2026-07-26T23:10:00Z", "sleep_end_at": "2026-07-27T06:50:00Z", "total_sleep_min": 280, "deep_sleep_min": 65, "light_sleep_min": 180, "rem_sleep_min": 35, "awake_min": 20, "sleep_onset_min": 15, "sleep_efficiency_pct": 71.0, "heart_rate": 72, "hrv": 45.3 }</pre>
2. 전처리	
전처리 과정	1. 이상치 정제 및 결측치 처리: 센서 신호 튀어짐(Noise)을 제거하고, 결측치는 보간하지 않고 해당 지표를 그날의 산출 대상에서 제외한다. 측정되지 않은 값을 0으로 채우면 활동량 급감과 구분되지 않는다. 2. 개인 기준선 산출: 사용자별 최근 14일 기록에서 지표별 중앙값과 중앙절대편차(MAD)를 구한다. 평균이 아니라 중앙값을 쓰는 이유는, 기기를 착용하지 않은 날 하나가 평균을 끌어내려 다음 날을 이탈로 오판하기 때문이다. 3. 이탈도 정량화: 당일 값을 개인 기준선 대비 robust z-score로 변환한다. 지표별로 위험한 방향을 정해 두고 그 방향의 이탈만 계상한다. 더 잘 잔 날은 이탈로 보지 않는다. 4. 시각 지표 변환: 입면 시각과 활동 개시 시각은 18시를 기준으로 한 경과 분으로 변환한다. 자정을 기준으로 하면 23:30에서 01:00으로 늦어진 것이 빨라진 것으로 계산된다.
전처리 데이터	전처리 데이터는 사용자·일자 단위의 이탈도 레코드이며, 7개 지표에 대한 개인 기준선 대비 robust z-score와 이탈 지표 목록·연속 이탈일수로 구성된다.

	지표: 총수면 · 걸음수 · 수면효율 · 입면지연 · 야간각성 · 입면시각 · 활동개시 산출값: 지표별 이탈도(z), 이탈 지표 목록(deviant_features), 연속 이탈일수(streak_days) (예시) <pre>{ "user_id": "c39a12e0-5712-42ba-822d-60603126f000", "collected_at": "2026-07-27", "deviations": { "총수면": 1.2, "걸음수": 0.8, "수면효율": 2.6, "입면지연": 3.1, "야간각성": 1.4, "입면시각": 2.2, "활동개시": 0.9 }, "deviant_features": ["입면지연", "수면효율", "입면시각"], "streak_days": 8 }</pre>
3. 데이터 분석	
데이터 분석 목표	집단 간 감정 분류가 아니라 개인 내 변화 탐지를 목표로 한다. 같은 수면 시간이라도 사람마다 평소가 다르므로, 절대값이 아니라 그 사용자의 평소 대비 이탈을 본다. 이탈이 일시적 편차가 아니라 지속되는 구간을 찾아 사용자가 스스로 인지하기 전에 접촉하는 것이 분석의 목적이다.
데이터 분석 시나리오	1. 기준선 대비 이탈 판정: 지표별 이탈도(z)가 임계치를 넘은 지표가 2개 이상인 날을 이탈일로 본다. 지표 하나만 튀는 것은 측정 오차일 수 있다. 2. 지속성 판정: 마지막 날부터 연속된 이탈일수를 센다. 연속 이탈이 이어지는 구간을 선제 접촉(MLCM_220)의 발동 조건으로 사용한다. 3. 대화 신호 결합: 챗봇 대화에서 산출된 감정 코드 및 위기 판정 결과를 함께 본다. 라이프로그 이탈과 대화 신호는 각각 독립적으로 산출되며, 어느 한쪽만으로도 판정이 성립한다. 4. 위험도 매핑: 감정 코드와 강도에 따라 3단계 위험도(NORMAL / CAUTION / CRITICAL)를 판정한다. CRISIS 감정은 강도와 무관하게 CRITICAL 로 확정하고 긴급 상담 연결을 트리거한다. 5. 근거 제시: 이탈이 큰 지표 목록을 함께 산출하여, 선제 접촉 발화가 무엇이 달라졌는지를 관찰 사실로 전달할 수 있게 한다.
데이터 분석 결과	분석 결과는 사용자·일자 단위의 정서 위험도 레코드로 산출된다. 라이프로그 이탈: anomaly_score, streak_days, deviant_features 정서 판정: emotion_code, emotion_score 위험도: risk_level, risk_score

	판정 근거: model_version model_version 은 판정 방식을 식별하는 값이며, 규칙 기반 판정은 rule- 접두사를 사용한다. 접두사가 rule- 인 결과는 학습된 모델의 출력이 아니므로 모델 성능의 근거로 인용하지 않는다. 운영 중인 값의 정보는 저장소 ai/server 의 구현이며, 본 문서는 명명 규칙만 규정한다.
4. 모델 생성 및 학습	
모델링 목표	다변량 시계열 라이프로그의 비정상 패턴 조기 탐지 및 3단계 위험도 판정. 감정 코드는 확보 가능한 데이터에 라벨이 없어 규칙 기반으로 산출한다.
학습 모델	- 목표 구조: LSTM Autoencoder(비지도 이상 감지) + LightGBM Classifier(지도 위험도 분류) - 현재 적용: 개인별 기준선 대비 이탈 규칙 판정. model_version 은 rule- 접두사로 규칙 기반임을 표시하며, 운영 값의 정보는 추론 서버 구현이다.
학습 방법	- 사용자(user_id) 단위 Group K-Fold Cross-Validation 으로 학습 타당성을 사전 검증한 결과, 확보 가능한 공개 데이터로는 목표 성능에 도달하지 못하여 본 과제에서는 모델 학습을 수행하지 않고 규칙 기반 판정을 적용한다. - GLOBEM 공개 샘플(참가자 40명)의 우울 이진 라벨 기준 ROC-AUC 0.528, 95% 신뢰구간 0.476~0.579 로 무작위 분류와 구분되지 않았다. - LifeSnaps(참가자 63명, 감정 라벨 7종)로 재검증한 결과도 ROC-AUC 0.479~0.540 로 동일하였으며, 특히 SAD(0.485)·TENSE/ANXIOUS(0.497)는 0.5 미만이었다. 참가자 수와 피처 수를 늘려도 결과가 변하지 않아 표본 부족이 아닌 신호 자체의 한계로 판단한다. - 무작위 분할 시 동일 참가자가 학습·평가에 함께 포함되어 ROC-AUC가 0.9 이상으로 과대평가되므로, 참가자 단위 분할을 반드시 유지한다. - 모델 교체 시 추론 서버의 반환 6필드 계약은 그대로 유지하며, model_version 값으로 규칙 판정 여부를 구분한다.
모델 예측 결과	입력 지표 수집 후 판정을 거쳐 감정 코드(emotion_code), 감정 점수(emotion_score), 이탈도(anomaly_score), 위험도(risk_level), 위험 점수(risk_score), 모델 버전(model_version) 6필드를 동시 산출한다. 연속 이탈일수(streak_days)와 이탈 지표 목록(deviant_features)을 함께 반환하여 선제 접촉(MLCM_220)의

	근거로 사용한다. 현재는 규칙 기반 판정이며 model_version 값이 rule- 로 시작한다. 모델로 교체하더라도 이 반환 계약은 동일하다.
5. 검증	
분석 검증 방안	1. 사용자(user_id) 단위 Group K-Fold Cross-Validation 으로 GLOBEM·LifeSnaps 공개 데이터셋의 학습 타당성을 사전 검증 함(근거는 위 「학습 방법」 참조) 2. 규칙 기반 판정 임계치가 정상·이상 시나리오에서 의도한 대로 NORMAL/CAUTION/CRITICAL 을 분기하는지 단위 테스트로 검증 3. 실제 생체 이상 파형 데이터 주입을 통한 고위험군 알림 트리거 응답 속도 및 임계치 성능 검증
분석 평가 결과	- 공개 데이터셋 기반 지도학습 모델은 목표 성능(Accuracy 85% ↑, F1-Score 0.80 ↑)에 도달하지 못해 채택하지 않음(근거는 위 「학습 방법」 참조) - 규칙 기반 판정으로 대체 적용하며, 고위험 상태 감지 시 비상 액션 트리거 지연 시간 3초 이내 검증 완수

기능명	대화 컨텍스트 기반 실시간 위기 대화 탐지
1. 데이터 준비	
데이터 정의	- 챗봇 상담 인터페이스에서 수집되는 사용자 대화 텍스트 문맥 및 이전 대화 히스토리 - 자살/자해 암시, 극단적 우울감 표현, 위기 단어(사망, 힘들, 끝내다 등) 포함 여부 및 대화 감정 상태
데이터 획득 방법	- 수집 방법 : 판정 로직 평가용 데이터셋은 팀이 직접 작성·라벨링하여 구축한다. 챗봇 세션 진행 중 사용자 입력 발생 시, 백엔드에서 판정 모듈로 실시간 전달한다. - 데이터 양 : 평가용 라벨링 데이터 200건 이상(위기·비위기 균형 구성). 운영 시 세션당 5~30개 대화 텍스트 레코드
수집 데이터	<pre>{ "session_id": "SESS_20260721_99", "user_id": "USER_1004", "timestamp": "2026-07-21T09:20:15Z", "turn_id": 5, "user_utterance": "요즘 너무 힘들고 다 내려놓고 싶어. 그냥 어 디론가 사라지고 싶다.", "dialogue_history": [{"turn": 3, "speaker": "user", "text": "잠도 못 자고 하루 종일 우울해."}, {"turn": 4, "speaker": "bot", "text": "많이 힘드셨겠어요. 무슨 일이 있으셨나요?"}] }</pre>
2. 전처리	
전처리 과정	1. 전화번호·이름 등 PII [MASK] 마스킹 2. 특수문자 및 공백 정제 3. 최근 N개 턴 대화 맥락 결합 4. 시스템 프롬프트와 결합하여 LLM 요청 페이로드 구성
전처리 데이터	LLM 입력용 프롬프트 페이로드(system instruction + 마스킹 완료 대화 맥락)
3. 데이터 분석	
데이터 분석 목표	단순 키워드 매칭을 넘어 사용자의 대화 맥락 전체를 분석함으로써 실제 위기 상황(자살/자해 위험, 고위험 정서 상태)을 실시간으로 정확히 탐지
데이터 분석	1. 사용자가 챗봇에 입력한 대화 텍스트가 AI 분석 서버로 실시간

시나리오	스트리밍 2. 1차 키워드 규칙 필터로 명백한 위기 표현을 즉시 판정하고, 통과한 발화는 2차 OpenAI LLM 문맥 분석 프롬프트로 위기 심각도를 분류한다. 3. 자해/극단선택 위기 단어 탐지 시 감정 코드를 CRISIS로 즉시 지정하고, 이전 라이프로그 점수와 무관하게 risk_level = CRITICAL, system_action = EMERGENCY 확정
데이터 분석 결과	CRISIS 감정 분류 플래그, risk_level(CRITICAL), system_action(EMERGENCY), 109 긴급 UI 트리거 신호
4. 모델 생성 및 학습	
모델링 목표	한국어 문맥 기반 위기 발화 탐지 재현율(Recall) 90% 이상 달성 및 1.5초 이내 판정 지연시간 확보
학습 모델	1차 키워드 규칙 필터(백엔드 내장) + 2차 OpenAI LLM 문맥 분석 프롬프트의 2단계 하이브리드 판정
학습 방법	별도 모델 학습을 수행하지 않고, 위기 심각도 분류 기준을 정의한 시스템 프롬프트를 설계하여 LLM에 주입한다. 프롬프트는 판정 결과를 정해진 JSON 스키마(is_crisis, severity, matched_context)로만 반환하도록 제약하여 파싱 안정성을 확보한다. severity 는 NONE, LOW, MEDIUM, HIGH, UNCLEAR 중 하나를 반환한다. UNCLEAR 는 발화만으로 위기 여부를 판별할 수 없어 추가 확인이 필요한 상태를 의미하며, 위기 아님(NONE)과 구분한다. 키워드 사전은 자해·극단선택 관련 표현을 중심으로 구성하며 운영 중 갱신 가능하도록 설정 파일로 분리한다. LLM 판정 결과(is_crisis, severity, matched_context)는 서비스 레벨 값으로 매핑되어 저장된다. is_crisis=true인 경우 risk_level을 CRITICAL로 확정하고 system_action을 EMERGENCY로 트리거하며, 원문 근거(matched_context)는 사후 검토용 로그에만 기록하고 대화 이력에는 저장하지 않는다.
모델 예측 결과	입력 대화 시퀀스에 대한 위기 여부 플래그 및 심각도 등급
5. 검증	
분석 검증 방안	- 자체 구축 고정 평가셋(위기·비위기 각 100건 내외)에 대한 Confusion Matrix 분석. 학습 과정이 없으므로 Train/Test Split 대신 전량 평가셋으로 측정한다.(평가셋은 프롬프트 설계자와 분리된 인원이 작성한다.) - 프롬프트 수정 시마다 동일 평가셋으로 재측정하여 회귀 여부를 점검한다.
분석 평가 결과	- 재현율(Recall) 90% 이상, F1-Score 0.85 이상 달성. - 단일 대화 판정 및 알림 트리거 응답 시간 1.5초 이내